


INTRODUÇÃO AO APRENDIZADO DE MÁQUINA

BREAST CANCER DIAGNOSIS DATASET

Anna Cristina, Eduardo Barros, Fábio Souza, Júlia Vilela e Leandro Omena



PLANEJAMENTO




TEMA

O câncer de mama exige diagnóstico rápido, mas a análise visual humana de biópsias gera filas e erros. O objetivo é criar um sistema de classificação supervisionada para atuar como ferramenta de segunda opinião médica na diferenciação de tumores benignos e malignos.




DATASET

Dataset Breast Cancer (Diagnostic) com 569 amostras de needle aspirate (FNA) de massas mamárias. Contém 30 atributos numéricos sobre características dos núcleos celulares e classifica tumores como benignos ou malignos.




TÉCNICAS

Técnicas que pretendemos testar: Regressão Logística, LDA, Árvore de Decisão, QDA e Redes Neurais.




0 DATASET

A large, stylized pink ribbon graphic is positioned on the left side of the slide, partially overlapping the text area. It is a solid pink color and has a thick, flowing appearance.


ORIGEM DOS DADOS

O dataset Breast Cancer Wisconsin não foi preenchido manualmente por médicos. Estas colunas são resultados diretos de algoritmos de visão computacional. Um software analisou imagens microscópicas (biópsias) dos tecidos mamários e calculou propriedades geométricas dos núcleos das células.

A large, stylized pink ribbon graphic is positioned on the left side of the slide, partially overlapping the text area. It is a solid pink color and has a thick, flowing appearance.

INTERPRETAÇÃO


Na prática clínica e microscópica, **células benignas** tendem a ser **redondas, lisas e com bordas uniformes**. Por outro lado, células de **tumores malignos** tendem a ser **deformadas, assimétricas e estruturalmente irregulares**. É exatamente essa deformidade geométrica que as features deste conjunto de dados estão capturando e quantificando.

A large, stylized pink ribbon graphic is positioned on the left side of the slide, partially overlapping the grid background. It is a solid pink color and has a thick, flowing appearance.

ANÁLISE DOS DADOS


- Limpeza de colunas redundantes
- Balanceamento
- Normalização dos dados
- Distribuição dos dados
- Métodos (logística/QDA)

MÉTODOS





REGRESSÃO LOGISTICA

Permite grande interpretabilidade, já que devolve uma probabilidade clara do “quão certo o modelo está”. Ideal para servir de ponto de partida.



QDA

Esse modelo é adequado quando queremos classificar grupos de dispersões completamente diferentes. Em nosso caso, o tumor benigno costuma variar pouco entre si, enquanto o maligno varia em raio, textura etc.



OBRIGADO!

